

RÉFÉRENCE

RAFT

DURÉE

3 jours

TARIF

2090 € HT

NIVEAU

Intermédiaire

À DISTANCE

Possible

VERSION

v2026-0512 (12/05/2026)

PROCHAINES SESSIONS

26 mai 2026

24 août 2026

02 déc. 2026

[Voir toutes les sessions](#)

RAG et Fine Tuning d'un LLM

Concevoir un système RAG et fine-tuner un LLM à l'aide des outils de l'écosystème Python

• DESCRIPTION DE LA FORMATION RAG FINE TUNING LLM

Qu'est-ce que RAG et le Fine Tuning d'un LLM ?

Le Retrieval-Augmented Generation (RAG) est une architecture hybride combinant la recherche d'information et la génération de texte à l'aide de modèles de langage (LLM). Le fine-tuning permet d'adapter un LLM à un domaine spécifique en le réentraînant sur des jeux de données ciblés, afin d'en améliorer la pertinence.

Pourquoi suivre une formation RAG et Fine Tuning d'un LLM ?

Les LLM ont transformé la manière dont on conçoit les assistants virtuels, les moteurs de recherche et les agents conversationnels. En Python, des bibliothèques comme HuggingFace Transformers, LangChain ou LlamaIndex permettent de créer des systèmes RAG puissants. Cette formation permet de concevoir et déployer un système RAG entièrement personnalisé, et de fine-tuner des modèles pour des cas d'usage métier avec Python.

• OBJECTIFS

Objectif opérationnel :

Savoir concevoir, entraîner et déployer un système RAG basé sur un LLM fine-tuné.

Objectif pédagogiques :

À l'issue de cette formation **RAG et Fine Tuning d'un LLM**, vous aurez acquis les connaissances nécessaires pour :

- Comprendre les principes de l'architecture RAG.
- Identifier les cas d'usage pertinents pour l'approche RAG.
- Maîtriser le fine-tuning de LLM en environnement Python.
- Intégrer une base documentaire dans une pipeline RAG.
- Déployer un système RAG avec les outils Python : LangChain, LlamaIndex, HuggingFace.

• PUBLIC ET PRÉREQUIS

Public cible :

Cette formation est destinée aux data scientists, ingénieurs IA, développeurs Python, architectes logiciels et chefs de projet techniques travaillant sur des projets d'IA générative.

Prérequis :

Bonne maîtrise du langage Python, connaissance des concepts de machine learning et expérience pratique avec les bibliothèques comme Pandas, Transformers ou PyTorch. Ces bases sont essentielles pour suivre le contenu technique dense de la formation.

• TRAVAUX PRATIQUES

Outils Python utilisés : Jupyter, HuggingFace Transformers, LangChain, LlamaIndex, Weaviate ou ChromaDB. 60 % de la formation repose sur des cas pratiques développés dans des notebooks Python.

• CONTENU DU COURS RAG FINE TUNING LLM

Jour 1

Introduction aux LLM et concepts RAG

Fonctionnement des LLM open-source, Deep Learning et Transformer

Les principaux LLM à notre disposition, Forces et faiblesses d'un LLM

Écosystème Python pour LLM : HuggingFace, LangChain, FAISS

Que sont le RAG et le Fine Tuning ?

Avantages, inconvénients des approches

Travaux pratiques

Objectif : Installer l'environnement Python et déployer un LLM open-source.

Description : Setup d'un environnement Conda, test d'un modèle via Transformers. Quel type de question échoue sans retrieval ?

Création d'un RAG simple avec Python

Les concepts clés du RAG, embedding, base de données vectorielles

Indexation de données

Mécanismes de récupération de données, recherche sémantique

Génération augmentée

Cas d'usage et enjeux stratégiques

RÉFÉRENCE

RAFT

DURÉE

3 jours

TARIF

2 090 € HT

NIVEAU

Intermédiaire

À DISTANCE

Possible

VERSION

v2026-0512 (12/05/2026)

PROCHAINES SESSIONS

26 mai 2026

24 août 2026

02 déc. 2026

[Voir toutes les sessions](#)

Travaux pratiques

Objectif :Réaliser un chatbot RAG en local.

Description :Extraction de texte, chunking, vectorisation, test d'un assistant LangChain. Quelle stratégie de découpage offre le meilleur rappel ?

Jour 2

Intégration dans un pipeline RAG

Pourquoi utiliser des Tool Chains ?

Les principaux outils de Pipeline : LangChain, LlamaIndex, Haystack

Création d'un Pipeline RAG avec LangChain

Agents LLM et logique ReAct, Exemples

Travaux pratiques

Objectif : Apprendre à intégrer rapidement un pipeline RAG avec LangChain

Description : Implémentation d'agents LangChain avec la logique ReAct, à travers un exemple concret d'application métier.

Fine-tuning avec HuggingFace

Fine Tuning Complet VS Fine Tuning léger (LoRA, QLoRA...)

Préparation des données : Nettoyage, format, annotations

Augmentation des données

Mise en oeuvre du Fine Tuning, APIs, ressources GPUs

Évaluation et métriques de performance

Distillation de modèles

Travaux pratiques

Objectif :Entraîner un modèle LoRA en local avec datasets personnalisés.

Description :Fine-tuning sur une base client, analyse des logs d'entraînement. Le modèle répond-il mieux aux requêtes internes ?

Jour 3

Déploiement, bonnes pratiques, optimisation et supervision

Quantization et compression d'un modèle

Déploiement d'un modèle fine tuned : Gradio, Streamlit

Le déploiement en API via FastAPI

Les logiciels Jan.ai et Ollama

Supervision avec LangSmith ou MLFlow

Travaux pratiques

Objectif :Conteneuriser un système RAG Python et simuler un usage réel.

Description :Création d'une interface Streamlit, simulation multi-utilisateurs. Quels risques liés à l'exposition du modèle à l'extérieur ?

Fine tuning vs RAG

Comparaison entre les deux techniques

Critères pour choisir la bonne approche

Combiner les approches pour améliorer les performances

Cas d'usage concrets et exemples

Travaux pratiques

Objectif : Mettre en pratique la complémentarité entre le Fine-Tuning et le RAG

Description : Mise en oeuvre d'une pipeline combinant un modèle LLM Fine tuné avec une approche RA : Préparation d'un jeu de données simplifié, intégration dans un pipeline RAG, Evaluation comparative des résultats

RÉFÉRENCE

RAFT

DURÉE

3 jours

TARIF

2 090 € HT

NIVEAU

Intermédiaire

À DISTANCE

Possible

VERSION

v2026-0512 (12/05/2026)

PROCHAINES SESSIONS

26 mai 2026

24 août 2026

02 déc. 2026

[Voir toutes les sessions](#)

• MOYENS PÉDAGOGIQUES

Les formations PLB sont conçues et animées par des experts en activité.

Les **cours pratiques** alternent **travaux pratiques**, concrets et progressifs construits sous forme de projet fil rouge, **et apports théoriques** (en moyenne 60% de travaux pratiques, 40% de théorie).

Les **séminaires** font alterner **études de cas et démonstrations** concrètes, issues de l'expérience terrain de nos formateurs, **et apports théoriques**.

Le support de cours et le cahier d'exercices incluant les corrigés sont fournis en français, au format PDF, et sont téléchargeables.

Chaque participant, en présentiel ou en classe virtuelle, accède aux travaux pratiques ou aux démonstrations via un poste de travail qui lui est dédié, configuré et équipé des logiciels et outils spécifiques présentés dans cette formation, dans leur dernière version.

Les cours et examens de certification officiels suivent les conditions de l'éditeur, du constructeur ou du certificateur. Ils sont susceptibles d'évoluer à tout moment.

La plupart des formations peuvent être suivies indifféremment en présentiel ou en classe à distance synchrone depuis votre entreprise ou votre domicile (voir les Modalités pédagogiques, techniques et de suivi spécifiques aux formations à distance).

Les salles sont équipées pour accueillir ces deux modalités: vidéoprojecteur, écran/tableau interactif, webcam et sonorisation, accès Internet très haut débit et espace documentaire partagé.

L'accès aux ressources pédagogiques, techniques et de suivi s'effectue via un espace personnel 100% digital. Le service d'assistance technique est joignable par chat et téléphone avant et pendant la formation.

Nos bâtiments sont classés ERP 5. En cas de handicap, contactez-nous par téléphone ou via l'adresse accessibilite@plb.fr afin de mettre en place l'équipement et l'accompagnement adaptés.

• MODALITÉS DE SUIVI

Les pré-requis sont évalués **par QCM** avant l'entrée en formation.

Les participants réalisent, **en début et en fin de formation, une auto-évaluation** de leurs connaissances et compétences au regard des objectifs pédagogiques de la formation.

L'évaluation des acquis en cours de formation est réalisée au fur et à mesure **des études de cas et/ou Travaux Pratiques** (50% du temps minimum pour les cours pratiques) **et/ou sous forme de QCM**.

L'évaluation en fin de formation est réalisée de la même façon et/ou via **le questionnaire d'auto-évaluation** qui permet de mesurer l'évolution par rapport au début de la formation et/ou par le passage de l'examen de certification, le cas échéant.

Les convocations, avec horaires définitifs, lieu et plan d'accès, sont envoyées deux semaines avant le début de la formation.

Les participants en classe virtuelle reçoivent leurs éléments de connexion par e-mail.

La feuille de présence numérique est à signer par demi-journée.

En fin de formation, les participants remplissent un questionnaire de satisfaction global.

Une attestation de réalisation est remise à la fin de la formation.

Si les conditions le permettent, nous pouvons inscrire jusqu'à 24h avant le début de la session. En cas d'inscription via le site [Moncompteformation](#), un délai de 11 jours ouvrés minimum est à respecter entre la proposition de commande et l'entrée en formation.